


[S1] Introduction



KNOWLEDGE DISCOVERY (KDD) PROCESS (2)

- Based on machine learning (ML) and statistics communities



knp data biasanya perlu di normalisasi? karena rata rata algoritma mengasumsikan bahwa datanya normal

feature selection

ketika milih fitur tentukan mau ke arah mana, jd fitur yang baik adalah yang selaras dengan objektif

gmn cara ngukur dampak tanpa label?

kenapa perlu di reduce? biar lebih cepat, ga berat

apa yg di evaluasi dari sebuah pola? menentukan voice dan noice, krn noice juga bisa berpola, misalnya buzzer dia noice tapi ada polanya

1. Apa itu Data Mining?

[cite_start]Kita sekarang hidup di era informasi, di mana data berukuran *terabytes* bahkan *petabytes* terus mengalir ke perangkat penyimpanan kita setiap harinya[cite: 27, 28]. [cite_start]Nah, **Data Mining** adalah proses untuk menemukan pola, model, dan *knowledge* (pengetahuan) yang menarik serta berharga dari kumpulan data yang sangat besar tersebut[cite: 29].

[cite_start]Istilah "mining" (menambang) dipakai karena proses ini mirip seperti mencari sedikit "emas" (informasi berharga) dari tumpukan material mentah (data) yang luar biasa banyak[cite: 30]. [cite_start]Proses ini juga sering dikenal dengan nama lain, seperti *Knowledge discovery from data* (KDD), *Data Analytics*, atau *Pattern discovery*[cite: 34, 35, 37].

Dalam dunia *Business Intelligence* (BI), Data Mining punya peran sentral. [cite_start]Posisinya ada di tengah piramida (biasanya dikerjakan oleh *Data Analyst*), di mana ia mengambil data yang sudah dirapikan (*Data Warehouse*) untuk mengekstrak informasi, yang nantinya divisualisasikan untuk membantu manajemen dalam mengambil keputusan bisnis (*Decision Making*)[cite: 40, 44, 47, 51, 56, 57].

2. Proses *Knowledge Discovery* (KDD)

[cite_start]Data mining sebenarnya adalah salah satu tahapan inti dari proses KDD yang lebih besar[cite: 64, 75]. Alur lengkapnya meliputi:

- [cite_start]**Data Preparation (Persiapan Data):** Meliputi pengumpulan data dari berbagai sumber, pembersihan data (*data cleaning*) dari *error* atau nilai kosong, dan integrasi data[cite: 65, 67, 69, 81]. [cite_start]Data kemudian dinormalisasi dan dipilih fiturnya (dimensinya direduksi) agar komputasinya lebih ringan[cite: 93, 94, 95].
- [cite_start]**Data Mining:** Tahap penemuan polanya itu sendiri, menggunakan berbagai teknik seperti klasifikasi, asosiasi, atau *clustering*[cite: 96, 98, 99, 100]. * [cite_start]**Post-Processing (Evaluasi & Presentasi):** Pola yang didapat kemudian dievaluasi, diinterpretasi, dan divisualisasikan menjadi *knowledge* yang mudah dipahami[cite: 92, 97, 103, 104].

3. Kategori dan Tugas Data Mining

[cite_start]Secara umum, data mining dibagi menjadi dua kategori utama[cite: 113]:

1. [cite_start]**Descriptive Data Mining:** Menjelaskan karakteristik atau properti dari data yang ada[cite: 114].
2. [cite_start]**Predictive Data Mining:** Melakukan induksi pada data untuk membuat prediksi di masa depan[cite: 115].

Tugas-tugas spesifiknya pasti udah nggak asing lagi buat kamu yang sering ngoprek algoritma *machine learning*:

- [cite_start]**Summarization:** Merangkum karakteristik data secara umum, misalnya membandingkan wilayah kering vs basah[cite: 124, 126].
- **Frequent Patterns & Associations:** Mencari item yang sering muncul bersamaan. [cite_start]Contoh klasiknya: mencari tahu barang apa saja yang sering dibeli barengan oleh pengunjung di supermarket[cite: 127, 128].
- [cite_start]**Classification & Regression:** Digunakan untuk memprediksi kelas atau tren di masa depan[cite: 129, 130].
- [cite_start]**Cluster Analysis:** Mengelompokkan data yang mirip untuk membentuk kategori-kategori baru[cite: 146, 147].
- [cite_start]**Deep Learning:** Aplikasinya sangat luas, termasuk untuk NLP dan *computer vision* (yang pastinya relevan banget untuk mengekstrak informasi dari gambar atau gestur)[cite: 149, 150, 151].
- [cite_start]**Outlier Analysis:** Mencari anomali atau data yang perilakunya sangat menyimpang dari tren umum[cite: 154, 155].

4. Kenapa Butuh Gabungan Banyak Ilmu?

[cite_start]Data mining nggak bisa berdiri sendiri sebagai satu disiplin ilmu murni[cite: 249]. [cite_start]Ia adalah titik temu (*confluence*) dari berbagai bidang seperti Statistik, *Machine Learning*, Sistem Database, Algoritma, sampai *High-performance computing*[cite: 198, 199, 200, 206, 209].

Kenapa harus gabungan? [cite_start]Karena data zaman sekarang ukurannya raksasa (*big data*), dimensinya tinggi, dan kompleksitasnya luar biasa[cite: 214, 216, 217]. [cite_start]Bentuk data bukan cuma tabel angka lagi, tapi juga teks, video, jaringan spasial, sampai data deret waktu yang membutuhkan kombinasi teknologi agar algoritmanya bisa berjalan efisien dan *scalable*[cite: 215, 219, 221].

5. Aplikasi dan Tantangan

[cite_start]Teknologi ini banyak dipakai untuk membangun *recommender systems* (sistem rekomendasi film/lagu), mesin pencari web, analisis data medis, hingga intelijen bisnis[cite: 230, 231, 233, 236]. [cite_start]Tapi, proses penerapannya juga punya tantangan utama (*major issues*), seperti bagaimana menangani data yang nggak lengkap dan penuh *noise*, efisiensi algoritmanya, serta memastikan privasi data tetap terjaga[cite: 240, 241, 242].