

[S5] Data Preparation II

[attachment:4cd90fa6-dc66-422e-8646-5ed5fe2f1d28:Session5_-_Data_Preparation_II.pdf](#)

1. Gambaran besar materi

Dalam proses **data mining**, data mentah jarang langsung siap dipakai untuk analisis atau pelatihan model. Data perlu disiapkan agar lebih bersih, seragam, efisien, dan representatif. Pada sesi ini, persiapan data dibahas melalui:

Data Transformation: mengubah nilai atau bentuk data agar lebih sesuai untuk analisis.

Data Reduction: mengurangi ukuran atau kompleksitas data tanpa kehilangan terlalu banyak informasi penting.

Dimensionality Reduction: mengurangi jumlah fitur/atribut agar model lebih efisien dan tidak terganggu oleh fitur yang tidak relevan.

2. Data Transformation

Data transformation adalah proses memetakan nilai lama dari suatu atribut menjadi nilai baru. Tujuannya bukan sekadar “mengubah angka”, tetapi membuat data lebih mudah dianalisis, lebih stabil untuk model, dan lebih sesuai dengan kebutuhan algoritma.

Metodenya mencakup:

Smoothing

Mengurangi noise atau fluktuasi acak dalam data. Misalnya, data penjualan harian yang naik-turun ekstrem bisa diratakan agar pola utamanya terlihat.

Attribute / feature construction

Membuat atribut baru dari atribut yang sudah ada. Contoh: dari `tanggal_lahir` dibuat fitur `usia`; dari `harga` dan `jumlah` dibuat `total_pembelian`.

Aggregation

Meringkas data. Misalnya, transaksi harian diringkas menjadi total bulanan.

Normalization

Menskalakan nilai agar berada dalam rentang tertentu, misalnya 0 sampai 1.

Discretization

Mengubah nilai kontinu menjadi interval/kategori, misalnya umur 18–25 = “muda”, 26–40 = “dewasa”.

3. Normalization

Normalization penting ketika atribut memiliki skala berbeda. Misalnya, `income` berada pada rentang ribuan sampai jutaan, sedangkan `age` hanya 0–100. Jika tidak dinormalisasi, algoritma berbasis jarak seperti K-Means atau KNN bisa terlalu dipengaruhi oleh atribut dengan angka besar.

a. Min-max normalization

Digunakan untuk mengubah data ke rentang tertentu, misalnya `[0, 1]`.

Rumusnya:

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A$$

Contoh pada slide: income dari 12.000 sampai 98.000 dinormalisasi ke `[0, 1]`. Nilai 73.000 menjadi:

$$\frac{73000 - 12000}{98000 - 12000} = 0.7093$$

Artinya, 73.000 berada sekitar 70,93% dari rentang minimum-maksimum data.

b. Z-score normalization

Mengubah nilai berdasarkan rata-rata dan standar deviasi.

$$v' = \frac{v - \mu}{\sigma}$$

Dengan mean 54.000 dan standar deviasi 16.000:

$$\frac{73000 - 54000}{16000} = 1.1875$$

Artinya, nilai 73.000 berada 1,1875 standar deviasi di atas rata-rata.

c. Decimal scaling

Menggeser koma desimal dengan membagi nilai menggunakan pangkat 10.

Contoh:

$$\frac{73000}{10^5} = 0.73$$

Metode ini sederhana, tetapi kurang fleksibel dibanding min-max atau z-score.

4. Discretization

Discretization adalah proses membagi nilai kontinu ke dalam interval. Misalnya, nilai umur, pendapatan, suhu, atau skor ujian diubah menjadi kelompok kategori.

Tujuannya:

Mengurangi ukuran data.

Menyederhanakan pola.

Membantu algoritma tertentu, terutama classification.

Membuat data lebih mudah ditafsirkan manusia.

Contoh:

Daripada memakai nilai umur asli **17, 23, 36, 58**, kita bisa membuat kategori:

0-17 = anak/remaja

18-35 = dewasa muda

36–60 = dewasa

>60 = lansia

Metode discretization pada slide mencakup:

Binning

Membagi data ke dalam bin. Bisa equal-width atau equal-depth.

Histogram analysis

Membagi rentang data berdasarkan distribusi frekuensi.

Clustering analysis

Membagi data berdasarkan kedekatan atau kelompok alami dalam data.

Decision tree analysis

Supervised method, menggunakan label kelas untuk menentukan titik split terbaik.

Correlation analysis / Chi-merge

Menggabungkan interval yang memiliki distribusi kelas mirip.

Pada gambar halaman 10, terlihat bahwa **K-Means clustering dapat menghasilkan pembagian interval yang lebih baik** daripada binning biasa karena clustering mengikuti pola alami data, bukan hanya membagi berdasarkan jarak atau jumlah data yang sama

5. Data Reduction

Data reduction bertujuan memperoleh representasi data yang jauh lebih kecil, tetapi tetap menghasilkan hasil analisis yang sama atau hampir sama.

Ini penting karena database atau data warehouse dapat berukuran sangat besar. Jika semua data dianalisis langsung, proses bisa sangat lambat dan mahal secara komputasi.

Metodenya terbagi menjadi dua:

a. Parametric methods

Metode ini mengasumsikan data mengikuti suatu model tertentu. Data asli kemudian bisa digantikan oleh parameter model.

Contoh:

Regression

Misalnya hubungan antara `bill` dan `tip` dapat direpresentasikan dengan persamaan garis. Kita tidak perlu menyimpan semua titik data untuk memahami pola umum; cukup simpan parameter model seperti slope dan intercept.

Log-linear model

Digunakan untuk merepresentasikan data multidimensi melalui kombinasi subruang marginal.

Kelebihannya: sangat ringkas.

Kekurangannya: bergantung pada asumsi model. Jika asumsi salah, hasil bisa bias.

b. Non-parametric methods

Metode ini tidak mengasumsikan bentuk model tertentu.

Contohnya:

Histogram

Meringkas distribusi data dalam bin.

Clustering

Mengelompokkan data dan memakai cluster sebagai representasi.

Sampling

Mengambil sebagian data yang representatif.

Kelebihannya: lebih fleksibel.

Kekurangannya: hasil sangat bergantung pada kualitas pemilihan bin, cluster, atau sampel.

6. Sampling

Sampling adalah mengambil sebagian kecil data `s` untuk mewakili seluruh dataset `N`.

Prinsip utamanya: sampel harus **representatif**.

Jenis sampling:

Simple random sampling

Setiap item punya peluang yang sama untuk dipilih.

Sampling without replacement

Setelah item dipilih, item tersebut dikeluarkan dari populasi sehingga tidak bisa terpilih lagi.

Sampling with replacement

Item yang sudah dipilih tetap bisa dipilih lagi.

Stratified sampling

Data dibagi ke dalam beberapa kelompok/strata, lalu sampel diambil dari tiap kelompok secara proporsional. Ini berguna jika dataset memiliki kelompok berbeda yang semuanya harus terwakili.

Contoh: jika dataset pelanggan terdiri dari 70% pengguna reguler dan 30% pengguna premium, stratified sampling menjaga proporsi itu tetap muncul dalam sampel.

7. Curse of Dimensionality

Ketika jumlah fitur semakin banyak, data menjadi semakin "jarang" atau sparse. Ini disebut **curse of dimensionality**.

Masalahnya:

Jarak antar titik menjadi kurang bermakna.

Clustering menjadi lebih sulit.

Deteksi outlier menjadi kurang akurat.

Kombinasi subspace meningkat secara eksponensial.

Model bisa menjadi lambat, kompleks, dan mudah overfitting.

Karena itu, **dimensionality reduction** digunakan untuk mengurangi jumlah variabel yang dipertimbangkan.

8. Dimensionality Reduction

Dimensionality reduction adalah proses mengurangi jumlah fitur sambil mempertahankan informasi penting.

Manfaatnya:

Menghindari curse of dimensionality.

Menghilangkan fitur tidak relevan.

Mengurangi noise.

Menghemat waktu dan memori.

Meningkatkan efisiensi model.

Ada dua pendekatan utama:

Feature selection

Memilih sebagian fitur asli yang paling penting.

Contoh: dari 100 atribut, hanya dipilih 15 atribut paling relevan.

Feature extraction

Mengubah fitur asli menjadi fitur baru berdimensi lebih rendah.

Contoh: PCA mengubah banyak fitur berkorelasi menjadi beberapa principal components.

9. Principal Component Analysis / PCA

PCA adalah teknik statistik untuk mengubah variabel yang mungkin saling berkorelasi menjadi variabel baru yang tidak saling berkorelasi, disebut **principal components**.

Intinya, PCA mencari arah baru dalam data yang menyimpan variasi terbesar.

Cara kerjanya:

Data dinormalisasi terlebih dahulu.

Dihitung covariance matrix.

Dicari eigenvector dan eigenvalue.

Eigenvector menjadi arah principal component.

Komponen diurutkan berdasarkan tingkat signifikansi/variasi.

Komponen lemah dengan variasi rendah dapat dibuang.

Pada contoh gambar halaman 20, bola diamati oleh tiga kamera. Karena gerakan bola sebenarnya mengikuti garis lurus, data dari tiga kamera mengandung banyak redundansi. PCA dapat mereduksi informasi berlebih tersebut menjadi representasi yang lebih kecil tetapi tetap bermakna

PCA hanya cocok untuk data numerik.

10. Attribute Subset Selection

Ini adalah bentuk lain dari dimensionality reduction dengan memilih atribut yang benar-benar berguna.

Ada dua jenis atribut yang sebaiknya dihapus:

Redundant attributes

Atribut yang informasinya duplikatif.

Contoh: harga produk dan pajak penjualan. Jika pajak selalu persentase tetap dari harga, keduanya sangat berkorelasi.

Irrelevant attributes

Atribut yang tidak berguna untuk tugas data mining.

Contoh: `student ID` biasanya tidak relevan untuk memprediksi GPA.

11. Attribute Creation / Feature Generation

Feature generation adalah membuat atribut baru yang lebih informatif daripada atribut asli.

Contoh:

Dari `tanggal transaksi`, buat fitur `hari`, `bulan`, `akhir pekan atau bukan`.

Dari `berat` dan `tinggi`, buat `BMI`.

Dari teks ulasan, buat fitur `sentiment score`.

Tiga metode umumnya:

Attribute extraction

Berbasis domain tertentu.

Mapping to new space

Misalnya Fourier transform, wavelet transform, atau manifold approach.

Attribute construction

Menggabungkan fitur lama menjadi fitur baru.

12. Jawaban exercise

1. Tujuan data transformation dalam KDD

Tujuannya adalah mengubah data mentah menjadi bentuk yang lebih cocok untuk mining dan model training. Ini penting karena model membutuhkan data yang bersih, konsisten, seimbang skalanya, dan informatif.

Tanpa transformation, model bisa:

bias terhadap fitur berskala besar,

lambat belajar,

sulit menemukan pola,

menghasilkan prediksi buruk,

terganggu noise dan atribut tidak relevan.

2. Teknik untuk menskalakan nilai 0 sampai 10.000 ke 0 sampai 1

Gunakan **min-max normalization**.

Karena targetnya jelas: semua nilai harus berada antara 0 dan 1.

Rumusnya:

$$v' = \frac{v - 0}{10000 - 0}$$

Jadi:

$$v' = \frac{v}{10000}$$

Contoh: nilai 7.500 menjadi 0,75.

3. Konsep PCA dan hubungannya dengan efisiensi model

PCA mengubah fitur-fitur yang saling berkorelasi menjadi principal components yang tidak saling berkorelasi. Komponen yang paling banyak menyimpan variasi dipertahankan, sedangkan komponen yang lemah dapat dibuang.

PCA meningkatkan efisiensi model karena:

- jumlah fitur berkurang,
- waktu training lebih cepat,
- kebutuhan memori lebih kecil,
- noise dan redundansi berkurang,
- model lebih sederhana,
- risiko overfitting dapat menurun.

Kesimpulannya, materi ini menjelaskan bahwa kualitas data sebelum modeling sangat menentukan kualitas hasil data mining. Data transformation membuat data lebih siap diproses, sedangkan data reduction dan dimensionality reduction membuat analisis menjadi lebih efisien tanpa mengorbankan terlalu banyak informasi penting.

Quiz

1. Jelaskan bagaimana minmax dan zscore dpt meningkatkan performa trus knp juga bisa mengaburkan makna asli dari data dlm konteks domain
2. Jelaskan hubungan sparsity, distance matrix degradation, relevansi fitur dlm proses pembelajaran mesin
3. Kapan pendekatan parametric jdi krg optimal dibandingkan non parametric?

GPT:

1. **(Key: normalization, performa model, interpretasi domain)** Min-max dan z-score meningkatkan performa karena menormalkan skala fitur sehingga algoritma berbasis jarak dan optimisasi bekerja lebih stabil dan adil antar fitur, namun dapat mengaburkan makna domain karena nilai asli berubah menjadi relatif (tidak lagi dalam satuan nyata), sehingga interpretasi bisnis atau batas penting dalam domain menjadi kurang jelas.
2. **(Key: sparsity, distance degradation, relevansi fitur, curse of dimensionality)** Ketika dimensi meningkat, data menjadi sparse sehingga jarak antar titik menjadi hampir sama (distance degradation), yang menyebabkan algoritma sulit membedakan pola, dan jika banyak fitur tidak relevan maka noise meningkat sehingga semakin menurunkan kemampuan model dalam belajar struktur data yang sebenarnya.
3. **(Key: parametric vs non-parametric, asumsi model, kompleksitas data)** Pendekatan parametric menjadi kurang optimal ketika data tidak sesuai dengan asumsi model (misalnya non-linear atau kompleks), karena model terlalu kaku dan cenderung underfitting, sedangkan non-parametric lebih unggul dalam kondisi ini karena fleksibel dan mampu menangkap pola tanpa asumsi bentuk distribusi tertentu.

Answer:

1. "sensitif terhadap range nilai" "interpretabilitas"
2. "sparsity: tingkat kekosongan data", semakin tinggi dimensi → resiko sparse tinggi. jadi semakin tinggi sparsity → semakin tinggi distance degradation → relevansi fitur semakin sulit ditemukan
3. "ketika data tidak sesuai asumsi model".
misalnya ada data A dan B, klo dia punya hubungan linear → model parametric works
ketika A dan B tidak punya hubungan linear → model parametric tidak works
di model non-parametric datanya itu tidak dimodelkan sehingga tidak bias ke model tersebut.
parametric: statis (terkunci terhadap asumsinya)
non-parametric: dinamis (mengikuti persebaran data)
kenapa ga selalu non-parametric aja? MAHAL!
untuk memitigasinya? kenali datanya dan polanya.

DATA TRANSFORMATION

- A function that maps the entire set of values of a given attribute to a new set of replacement values such that each old value can be identified with one of the new values
- Methods
 - Smoothing: remove noise from data
 - Attribute/feature construction: new attributes constructed from the given ones
 - Aggregation: summarization, data cube construction
 - Normalization: scaled to fall within a smaller, specified range
 - Discretization: concept hierarchy climbing

trans: transisi (perubahan)

formation: formasi (bentuk)

jadi data transformation merubah bentuk datanya tanpa mengubah informasinya

smoothing bisa pake MA (moving average), gaussian rule (untuk gambar/warna)

smoothing biasanya untuk domain waktu, gambar

attribute/feature extraction: OHE/OE/LE/tgl → umur

agregasi: 365 hari → 12 bulan/52 week

normalisasi: min-max scalling

discretization:

DATA TRANSFORMATION : NORMALIZATION

Normalization

- Min-max normalization: to $[new_min_A, new_max_A]$

$$v' = \frac{v - min_A}{max_A - min_A} (new_max_A - new_min_A) + new_min_A$$

- Z-score normalization (μ : mean, σ : standard deviation):

$$v' = \frac{v - \mu_A}{\sigma_A}$$

- Normalization by decimal scaling:

$$v' = \frac{v}{10^j}$$

where j is the smallest integer such that $Max(|v'|) < 1$.

paling aman normalisasi pake z-score (cuman mahal, butuh komputer spek tinggi),
karena bisa tau mana data yang terjatuh di kanan atau di kiri distribusi

paling cepet pakai decimal scalling

klo bisa lebih dari decimal → pake min-max → z-score

DATA TRANSFORMATION : EXAMPLE NORMALIZATION

- Example:

E.g., let income range \$12,000 to \$98,000 normalized to [0.0, 1.0] while $\mu=54,000$ and $\sigma=16,000$. What is \$73,000 mapped to?

Answer:

- Min-max normalization

$$\frac{73,000 - 12,000}{98,000 - 12,000} (1.0 - 0.0) + 0.0 = 0.7093$$

- Z-score normalization

$$\frac{73,000 - 54,000}{16,000} = 1.1875$$

- Normalization by decimal scaling

$$\frac{73,000}{10^5} = 0.73$$

yang paling informatif: decimal

paling intuitive (misalnya jadi tau klo nilainya itu di atas rata"): z-score

paling ywda aja yang penting dinormalisasi: min-max


DATA TRANSFORMATION : DISCRETIZATION

- **Discretization:** Divide the range of a continuous attribute into intervals
 - Interval labels can then be used to replace actual data values
 - Reduce data size by discretization
 - Supervised vs. unsupervised
 - Split (top-down) vs. merge (bottom-up)
 - Discretization can be performed recursively on an attribute
 - Prepare for further analysis, e.g., classification
- All **methods** can be applied recursively, i.e., binning, histogram, clustering, decision tree, and correlation analysis, ...


DATA TRANSFORMATION : DISCRETIZATION

- **Binning:** Top-down split, unsupervised
- **Histogram analysis:** Top-down split, unsupervised
- **Clustering analysis:** Unsupervised, top-down split or bottom-up merge
- **Decision-tree analysis:** Supervised, top-down split
- **Correlation analysis:** Unsupervised, bottom-up merge


DISCRETIZATION WITHOUT SUPERVISION: BINNING VS. CLUSTERING




Data



Equal width (distance) binning



Equal depth (frequency) (binning)



K-means clustering leads to better results

kmeans paling bagus


DISCRETIZATION BY CLASSIFICATION & CORRELATION ANALYSIS

- Classification (e.g., decision tree analysis)
 - Supervised: Given class labels, e.g., cancerous vs. benign
 - Using entropy to determine split point (discretization point)
 - Top-down, recursive split
 - Details to be covered in Chapter "Classification"
- Correlation analysis (e.g., Chi-merge: χ^2 -based discretization)
 - Supervised: use class information
 - Bottom-up merge: Find the best neighboring intervals (those having similar distributions of classes, i.e., low χ^2 values) to merge
 - Merge performed recursively, until a predefined stopping condition

DATA REDUCTION : DATA COMPRESSION

- Data Compression: String Compression or Audio/Video Compression

- Type of compression:



- Data reduction and dimensionality reduction may also be considered as forms of data compression


lossless: ga bisa dibalikin ke aslinya

lossy: bisa dibalikin ke aslinya

confirm lagi (lupa, takut salah denger)

DATA REDUCTION : SAMPLING

- Sampling: obtaining a small sample s to represent the whole dataset N
- Key principle: Choose a representative subset of the data



TYPE OF SAMPLING

- **Simple random sampling:** equal probability of selecting any particular item
- **Sampling without replacement**
 - Once an object is selected, it is removed from the population
- **Sampling with replacement**
 - A selected object is not removed from the population
- **Stratified sampling**
 - Partition (or cluster) the data set, and draw samples from each partition (proportionally, i.e., approximately the same percentage of the data)

sampling diperbolehkan selama merepresentasikan karakteristik origin-nya.

SRSWOR: menghilangkan karakteristik data utamanya, biasanya hanya digunakan untuk data yang sangat-sangat besar

SRSWR: untuk menjaga kemiripan distribusi data sampling dengan data aslinya

stratified sampling: sampling yang dilakukan dengan menjaga rasio



gimana cara SRSWR tau itu sama mewakili karakteristik? klo gitu kenapa ga pake SRSWR terus aja?





DATA REDUCTION

- To obtain a reduced representation of the dataset that is much smaller in volume but yet produces the same (or almost the same) analytical results
- Why data reduction?—A database/data warehouse may store terabytes of data
 - Complex analysis may take a very long time to run on the complete data set
- Methods for data reduction (also data size reduction or numerosity reduction)
 - Parametric: Regression and Log-Linear Models
 - Non-parametric: Histograms, clustering, sampling


tujuannya: biar murah, biar ga overfit

DATA REDUCTION: PARAMETRIC VS. NON-PARAMETRIC METHODS

- Reduce data volume by choosing alternative, smaller forms of data representation
- Parametric methods (e.g., regression)
 - Assume the data fits some model, estimate model parameters, store only the parameters, and discard the data (except possible outliers)
 - Ex.: Log-linear models—obtain value at a point in m-D space as the product on appropriate marginal subspaces
- Non-parametric methods
 - Do not assume models
 - Major families: histograms, clustering, sampling, ...



Clustering on the Raw Data



Stratified Sampling

parametric: regression

non-parametric: clustering

DATA REDUCTION : DIMENSIONALITY

- Curse of dimensionality
 - When dimensionality increases, data becomes increasingly sparse
 - Density and distance between points, which is critical to clustering, outlier analysis, becomes less meaningful
 - The possible combinations of subspaces will grow exponentially
- Dimensionality Reduction: Reducing the number of random variables under consideration, via obtaining a set of principal variables
- Advantages of dimensionality reduction
 - Avoid the curse of dimensionality
 - Help eliminate irrelevant features and reduce noise
 - Reduce time and space required in data mining

bisa di dimensi baris, bisa juga di column



DIMENSIONALITY REDUCTION METHODS


- Dimensionality reduction methodologies
 - Feature selection: Find a subset of the original variables (or features, attributes)
 - Feature extraction: Transform the data in the high-dimensional space to a space of fewer dimensions
- Some typical dimensionality reduction methods
 - Principal Component Analysis
 - Attribute Subset Selection
 - Nonlinear Dimensionality Reduction

cara reduce:

- feature selection: klo kelebihan
- feature extraction: klo kekurangan

PRINCIPAL COMPONENT ANALYSIS (PCA)

- PCA: A statistical procedure that uses an orthogonal transformation to convert a set of observations of possibly correlated variables into a set of values of linearly uncorrelated variables called principal components
- The original data are projected onto a much smaller space, resulting in dimensionality reduction
- Method: Find the eigenvectors of the covariance matrix, and these eigenvectors define the new space
- Works for numeric data only



PCA

PRINCIPAL COMPONENT ANALYSIS (PCA)

- Given N data vectors from n -dimensions, find $k \leq n$ orthogonal vectors (principal components) best used to represent data
 - Normalize input data: Each attribute falls within the same range
 - Compute k orthonormal (unit) vectors, i.e., principal components
 - Each input data (vector) is a linear combination of the k principal component vectors
 - The principal components are sorted in order of decreasing “significance” or strength
 - Since the components are sorted, the size of the data can be reduced by eliminating the weak components, i.e., those with low variance (i.e., using the strongest principal components, to reconstruct a good approximation of the original data)

ATTRIBUTE SUBSET SELECTION

- Another way to reduce dimensionality of data
- Redundant attributes
 - Duplicate much or all of the information contained in one or more other attributes
 - E.g., purchase price of a product and the amount of sales tax paid
- Irrelevant attributes
 - Contain no information that is useful for the data mining task at hand
 - Ex. A student's ID is often irrelevant to the task of predicting his/her GPA

ATTRIBUTE CREATION (FEATURE GENERATION)

- Create new attributes (features) that can capture the important information in a data set more effectively than the original ones
- Three general methodologies
 - Attribute extraction: Domain-specific
 - Mapping data to new space (see data reduction): E.g., Fourier transformation, wavelet transformation, manifold approaches (not covered)
 - Attribute construction: Combining features (see discriminative frequent patterns in Chapter on "Advanced Classification"), Data discretization

fourier transform (banyak turunan): ngubah data dari domain spasial → domain frequency

TUJUAN UTAMA REDUKSI: EFEKTIFITAS dan EFISIENSI

SUMMARY

- Data transformation: normalization, discretization, data compression and sampling
- Data reduction: Parametric (Regression and Log-Linear Models), Non-parametric (Histograms, clustering, sampling)
- Dimensionality Reduction: Reducing the number of random variables under consideration, via obtaining a set of principal variables